Relatório de experimentos

Reconhecimento de Pokémon em vídeo com MobileNetV2

> Usei os vídeos, frames e saídas anotadas que estão no projeto. Quando uma gravação específica não existe, deixei isso claro em vez de inventar um rótulo ou uma confiança.

Dados usados

O conjunto tem Bulbasaur, Charmander, Squirtle e fundo, com quatro vídeos por classe. O extrator gerou 112 imagens de Bulbasaur, 127 de Charmander, 267 de fundo e 181 de Squirtle. Como as gravações de fundo são quase paradas, a extração manteve frames parecidos para não deixar essa classe com poucas imagens.

1. Por que separar treino e validação por vídeo?

Comparei duas divisões. Na primeira, vídeos inteiros ficaram de fora do treino. Na segunda, sorteei 20% das imagens de cada classe, podendo deixar frames do mesmo vídeo dos dois lados. No split por vídeo, a validação usou `bulbasaur_cima_video`, `charmander_cima`, `fundo3` e `squirtle_cima`.

Divisão	Acurácia	Loss	Resultado
Por vídeo	96,3%	0,113	Avalia gravações que o modelo não viu.
Por foto	100%	0,004	Mais otimista: frames vizinhos podem aparecer no treino e na validação.

O 100% do split por foto não representa tão bem o uso real: frames vizinhos são quase iguais, então o modelo pode acertar por já ter visto uma imagem parecida. Entre os dois números, 96,3% por vídeo é a estimativa mais confiável. No teste anotado de 45,8 segundos, amostras aos 0, 5 e 10 segundos mostraram Bulbasaur a 100%; aos 20 e 25, Charmander a 85% e 100%; e dos 35 aos 45, Squirtle a 100%. Perto das transições houve Squirtle a 92% aos 15 segundos e `?` a 59% aos 30. Isso é uma leitura de alguns momentos, não uma acurácia calculada do vídeo inteiro.

2. O fine-tuning ajudou?

Comparei a fase com a MobileNetV2 congelada ao fine-tuning com `1e-5`. Depois repeti o ajuste com `1e-3`, partindo dos mesmos pesos da fase 1.

Etapa	Acurácia	Loss	Observação
Só a cabeça	95,7%	0,174	7 frames de Squirtle foram previstos como Charmander.
Fine-tuning 1e-5	96,3%	0,113	Pequena melhora; ainda houve confusões com Squirtle.
Fine-tuning 1e-3	86,2%	0,265	Acurácia começou em 68,6%; a loss variou durante as épocas.

Com `1e-5`, a loss de validação caiu e a acurácia subiu um pouco, então o ajuste ajudou modestamente. Com `1e-3`, a loss começou em 0,683, oscilou e terminou em 0,265, acima de 0,113. A taxa alta altera os pesos pré-treinados em passos grandes; uma taxa baixa permite adaptar a rede sem desorganizar tanto o que ela já aprendeu.

2. Matrizes de confusão

As linhas são a classe real e as colunas a classe prevista. A ordem é Bulbasaur, Charmander, fundo e Squirtle.

Só a cabeça	Bulbasaur	Charmander	Fundo	Squirtle
Bulbasaur	25	0	0	1
Charmander	0	47	0	0
Fundo	0	0	64	0
Squirtle	0	7	0	44

Fine-tuning 1e-5	Bulbasaur	Charmander	Fundo	Squirtle
Bulbasaur	26	0	0	0
Charmander	0	47	0	0
Fundo	0	0	64	0
Squirtle	3	4	0	44

3. O modelo reconhece o Pokémon de qualquer ângulo?

Ainda não dá para afirmar. Os vídeos de treino mostram frente, cima, baixo e perto; não há gravação de costas. Por isso, não fiz o retreino sem costas nem a avaliação controlada desse ângulo. Visualmente, Bulbasaur tem corpo verde e bulbo, Charmander é alaranjado com cauda, e Squirtle é azul e tem casco. Essas diferenças parecem úteis para uma pessoa, mas não medimos quais características a rede usa por dentro.

Para melhorar, eu (1) gravaria costas e os dois lados de cada Pokémon em fundos variados; e (2) incluiria mais poses e escalas reais no treino, complementadas por rotações, mudanças de zoom e enquadramento. Assim o modelo veria os ângulos novos em mais de um cenário.

4. O que acontece com um Pokémon que o modelo não conhece?

Não há uma gravação isolada de um quarto Pokémon nos arquivos, então não posso informar qual rótulo ou confiança ele recebeu. A saída softmax distribui 100% entre as quatro classes conhecidas: Bulbasaur, Charmander, fundo e Squirtle. Para um Pokémon novo, o maior valor ainda pode pertencer a uma classe conhecida. O detector usa a média dos últimos oito frames: abaixo de 60%, mostra `?`; acima disso, mostra o nome da classe de maior valor.

Fundo ajuda quando a imagem se parece com as telas vazias do treino, mas não significa ‘qualquer coisa desconhecida’. Um Pokémon que não estava no treino pode parecer com uma classe conhecida e receber um palpite confiante. O limiar reduz palpites fracos, mas não garante reconhecer novidade.

5. Classificação ou detecção?

Na saída anotada `saida_teste-pokemons.mp4`, há vários Pokémon e imagens visíveis na tela. Em amostras, o detector alternou entre `?` com 48–55% e Squirtle com 62–97%, sem indicar qual personagem da tela estava classificando. Isso não é o teste controlado com dois bonecos lado a lado, mas mostra a limitação: o modelo classifica o quadro inteiro e não separa os itens.

Classificação retorna uma classe para a imagem toda; não informa posição nem vários objetos. Para encontrar todos, eu anotaria cada Pokémon com uma caixa e um rótulo e treinaria um detector, como YOLO. Na execução, ele retornaria uma caixa, classe e confiança por Pokémon, e o programa desenharia todas as caixas.

> Ainda faltam para fechar a entrega: gravar um quarto Pokémon sozinho, fazer o teste controlado de costas e gravar dois Pokémon lado a lado. Também guarde o print da linha do tempo do vídeo de teste.